

Matriz de costos — Selección de modelo de IA

1. Tarea a resolver

Un único punto de procesamiento IA en todo el flujo: analizar una imagen de comprobante de pago y devolver, en JSON estructurado, si es válido y sus datos (monto, fecha, método). Es una tarea de **clasificación + extracción simple**, no requiere razonamiento complejo ni memoria conversacional.

2. Modelos evaluados (con capacidad de visión)

Modelo	Precio entrada (por 1M tokens)	Precio salida (por 1M tokens)	Nivel gratuito	Observaciones
Claude Haiku 4.5	\$1.00	\$5.00	No	Modelo más económico de Anthropic; buena calidad de visión
Gemini 3.5 Flash-Lite  elegido	\$0.30	\$2.50	Sí	Modelo “lite” más reciente de Google con capacidad de visión; ~3x más barato que Haiku en entrada
Gemini 3.5 Flash	\$1.50	\$9.00	Sí	Más capacidad de razonamiento, no necesaria para esta tarea
GPT-4.1 nano	\$0.10	\$0.40	No	Más barato en el papel, pero sin nivel gratis y requiere otra cuenta/proveedor

3. Justificación de la elección

Se eligió **Gemini 3.5 Flash-Lite** por tres motivos concretos:

1. **La tarea no exige capacidad de razonamiento avanzada.** Es una clasificación binaria + extracción de 3 campos desde una imagen — el modelo más liviano de la categoría “con visión” alcanza y sobra.
2. **Nivel gratuito.** Dado el volumen esperado (pocos comprobantes por semana en un salón de eventos), el uso real cae dentro de la cuota gratuita de Google AI Studio, llevando el costo operativo a **\$0 durante toda la vida del proyecto de la entrega.**
3. **Vigencia del modelo.** A diferencia de la generación anterior (Gemini 2.5), que Google retiró para nuevas integraciones, esta es la línea “lite” vigente al momento de la entrega.

Se descartó Claude Haiku (usado en una primera etapa del desarrollo) porque, si bien es confiable y de buena calidad, no ofrece nivel gratuito y su costo de entrada es más de 3 veces mayor sin aportar valor adicional a esta tarea puntual.

4. Estimación de ahorro

Supuesto de volumen: 20 comprobantes procesados por mes, ~1.500 tokens de entrada (imagen +

prompt) y ~150 tokens de salida (JSON) por análisis.

Modelo	Costo mensual estimado
Claude Haiku 4.5	$20 \times [(1.500/1M \times \$1) + (150/1M \times \$5)] \approx$ \$0.045/mes
Gemini 3.5 Flash-Lite	$20 \times [(1.500/1M \times \$0.30) + (150/1M \times \$2.50)] \approx$ \$0.0165/mes

Ahorro estimado: ~63% del costo de IA, aunque en términos absolutos ambos son montos marginales dado el bajo volumen — el valor real de la elección está en el nivel gratuito, que lleva el costo a cero mientras dure el uso académico.

5. Consideración a futuro (fuera del alcance de esta entrega)

Si el sistema escalara a un uso real y sostenido con múltiples salones/clientes, se recomendaría: - Reevaluar el modelo periódicamente, dado el ritmo acelerado de nuevas versiones en la industria (en el desarrollo de este mismo proyecto, Google retiró la serie 2.5 y lanzó la 3.x). - Si el volumen de comprobantes creciera a cientos por día y no se necesitara respuesta inmediata, evaluar la **Batch API** de Anthropic o Google (~50% de descuento adicional) para procesamiento asincrónico masivo.